

TRABAJO INICIAL

Economía del Desarrollo

Universidad de Piura
Facultad de Economía

Profesor:

Paul Josemaría Corcuera García

Autores:

Fernando Cotrina Lejabo
Joaquín Ato Rivera

Fecha de entrega:

Octubre 2025

Errores Estándar y Clustering en Diseños Experimentales

- 1 En esta pregunta vamos a explorar la disyuntiva entre usar clustering o errores estándar robustos en diseños experimentales (por ej. programas sociales). Se adjunta en el trabajo un do-file llamado P2.E2DES.do que hace lo siguiente.

Se generan 100 sitios (clusters) con 100 observaciones dentro de cada uno, y siguiendo el siguiente proceso generador de datos:

$$\begin{aligned}Y_{ic} &= \nu_c + D_{ic} \eta_c + \varepsilon_{ic} \\D_{ic} &= I[D_{ic}^* > .5] \\D_{ic}^* &\sim U[0, 1] \\\eta_c &\sim N(1, \sigma_\eta^2), \quad \nu_c \sim N(0, 1) \\\varepsilon_{ic} &\sim N(0, 1)\end{aligned}$$

donde i es un individuo viviendo en el sitio c , D_{ic}^* representa las chances de ser tratado que son independientes del término de error ε_{ic} , η_c representa efectos heterogéneos que tiene el tratamiento en cada sitio, y ν_c indica que los interceptos son heterogéneos según el sitio en el que vives.

En otras palabras, estamos intentando representar el efecto de un tratamiento aleatorio D_{ic} asignado a nivel individual con probabilidad $1/2$, el cual tiene efectos heterogéneos η_c en los distintos clusters (sitios) pero su efecto en promedio es 1 (la media de este parámetro η_c). Haber sido no tratado igual tiene efectos heterogéneos por sitio capturados por ν_c .

- a) Corran la parte del apartado A) en el do-file para simular la data usando $\sigma_\eta^2 = 1$. ¿Qué errores estándar obtienen para el caso homoscedástico, robusto y cluster?

Al simular los datos con una varianza del efecto de sitio de $\sigma_\eta^2 = 1$ se está asumiendo que existe variabilidad significativa entre los sitios, es decir, que los contextos locales generan diferencias sistemáticas en los resultados, incluso bajo el mismo tratamiento. Esto implica que los individuos dentro de un mismo sitio están correlacionados entre sí, ya que comparten el mismo efecto. En este escenario, los errores entre individuos del mismo grupo no son independientes, lo que hace necesario utilizar errores estándar agrupados (cluster) para obtener inferencias válidas.

La Tabla 1 muestra los resultado de estimar el modelo bajo diferentes supuestos sobre la estructura del error. En primer lugar, el coeficiente del tratamiento D es de 0.960 en las tres especificaciones, manteniéndose muy cercano al valor esperado de 1 y mostrando alta significancia estadística en todos los casos. Esto indica que, en promedio, el efecto estimado del tratamiento es consistente independientemente del método de estimación de varianzas utilizado.

Sin embargo, al examinar los errores estándar encontramos diferencias grandes. Los errores clusterizados (0.111) son casi 3.5 veces mayores que los homoscedásticos (0.032) y robustos (0.032). Esta disparidad refleja la presencia de correlación intra-grupo que los primeros dos métodos no logran capturar adecuadamente. Cuando los individuos dentro de un mismo cluster comparten características no observadas, los errores estándar convencionales subestiman la verdadera variabilidad, dando una falsa sensación de precisión.

Table 1: Comparación de Errores Estándar - $\sigma_\eta^2 = 1$

	Método de Estimación		
	Homoscedástico	Robusto	Cluster
	(1)	(2)	(3)
Variable D			
Coefficiente	0.960***	0.960***	0.960***
Error Estándar	(0.032)	(0.032)	(0.111)
Estadístico t	(29.59)	(29.64)	(8.63)
Constante			
Coefficiente	-0.079***	-0.079***	-0.079
Error Estándar	(0.023)	(0.020)	(0.107)
Estadístico t	(-3.45)	(-3.89)	(-0.74)
Observaciones (N)	10,000	10,000	10,000
R-cuadrado (R^2)	0.081	0.081	0.081

Notas: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

Las implicancias para la inferencia estadística son relevantes. Mientras los estadísticos t de los modelos homocedástico (29.59) y robusto (29.64) sugieren un nivel de significancia extremadamente alto, el estadístico t con errores clusterizados (8.63), aunque continúa siendo estadísticamente significativo, resulta considerablemente más conservador y realista. Esta diferencia se acentúa al analizar la constante del modelo, cuya significancia desaparece al emplear errores clusterizados. Ello evidencia cómo las conclusiones respecto a los efectos fijos pueden variar de manera sustantiva según el tratamiento de la correlación intra-grupo.

- b) Corran la parte del apartado B) en el do-file para simular la data usando $\sigma_\eta^2 = 0$. Ahora estamos asumiendo que los efectos del tratamiento son homogéneos a través de los distintos sitios. ¿Cómo cambian los errores estándar en este caso en comparación con la parte a)? Comente las diferencias.

En este segundo escenario, al establecer $\sigma_\eta^2 = 0$, eliminamos por completo el componente aleatorio a nivel de sitio. El término η_c desaparece del modelo de generación de datos, lo que implica que no existe ninguna fuente de heterogeneidad no observada a nivel de clúster. En este contexto, las observaciones son genuinamente independientes y no correlacionadas dentro de los grupos. Por lo tanto, los supuestos estándar de MCO se cumplen y no se esperaría una diferencia sustancial entre los distintos métodos de cálculo de los errores estándar.

La Tabla 2 confirma esta predicción. En primer lugar, se observa que los errores estándar son similares en cada especificación, esto debido a que no existe correlación intra-cluster atribuible a η_c . Y, por consiguiente, los errores estándar homoscedásticos o robustos deberían ser apropiados y la corrección por agrupamiento (cluster) no aportaría una corrección relevante.

En el escenario anterior, con $\sigma_\eta^2 = 1$, no ajustar por clúster llevaba a una subestimación de los errores estándar y, consecuentemente, a un excesivo rechazo de la hipótesis nula, inflando la prob-

abilidad de cometer un error de Tipo I. En cambio, en este segundo caso, donde la clusterización es innecesaria, su aplicación no resulta perjudicial para la inferencia del coeficiente de interés.

Table 2: Comparación de Resultados - $\sigma_\eta^2 = 0$

	Método de Estimación		
	Homoscedástico	Robusto	Cluster
	(1)	(2)	(3)
Variable D			
Coefficiente	0.951***	0.951***	0.951***
Error Estándar	(0.028)	(0.028)	(0.028)
Estadístico t	(33.54)	(33.53)	(34.51)
Constante			
Coefficiente	-0.079***	-0.079***	-0.079
Error Estándar	(0.020)	(0.020)	(0.107)
Estadístico t	(-3.95)	(-3.89)	(-0.74)
Observaciones (N)	10,000	10,000	10,000
R-cuadrado (R^2)	0.101	0.101	0.101

Notas: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$.

Respecto a la constante, se observa una discrepancia en su error estándar clusterizado, que es mayor al de los otros dos métodos. Esto puede ser un artefacto de la simulación o reflejar otras fuentes menores de heterogeneidad en el modelo. Sin embargo, el punto central es que la inferencia sobre la variable de política, D , que es el foco del análisis, ya no se ve afectada por la elección del método de estimación de la varianza una vez que se elimina la principal fuente de correlación intra-grupo.

En resumen, la comparación de ambos escenarios pone de manifiesto la importancia crítica de alinear la estimación de la matriz de varianzas y covarianzas con la estructura de datos. Ignorar una correlación intra-grupo existente (caso a) conduce a inferencias incorrectas y excesivamente optimistas. Por el contrario, cuando dicha correlación es inexistente (caso b), los métodos de estimación estándar son suficientes y la corrección por clúster, aunque no necesaria, no distorsiona la inferencia sobre el parámetro de interés.

- c) Corriendo el apartado C) en el do-file estamos realizando un experimento de Monte Carlo para repetir la data experimental 1000 veces distintas asumiendo $\sigma_\eta^2 = 1$. En cada caso está calculando si se rechaza la hipótesis nula de que el tratamiento tiene efecto promedio igual a 1 bajo errores estándar homoscedásticos, robustos y cluster.

Según los resultados mostrados en pantalla, ¿qué fracción de las veces se rechaza la hipótesis nula de que el coeficiente de la regresión es igual a 1? ¿A qué valor deberían aproximarse normalmente estas fracciones, según su conocimiento de tests de hipótesis?

Al realizar el experimento de Monte Carlo, asumiendo $\sigma_\eta^2 = 1$, es decir, que existen diferencias entre sitios; evaluando si se rechazaba la hipótesis nula de que el tratamiento tiene un efecto prome-

dio igual a 1, utilizando tres tipos de errores estándar: homoscedásticos, robustos y agrupados estos fueron los resultados:

Table 3: Tasas de Rechazo de H_0 : $\beta = 1$

Tipo de Error Estándar	Tasa de Rechazo
Homoscedástico	52.5%
Robusto	52.5%
Agrupado (Cluster)	4.3%

En teoría, si el test está bien calibrado y el nivel de significancia es del 5%, se esperaría que estas fracciones se aproximen a 0.05.

Sin embargo, los resultados muestran que los tests homoscedástico y robusto rechazan la hipótesis nula en aproximadamente el 52.5% de los casos, es decir, más de diez veces lo esperado, lo que indica un exceso de falsos positivos. En cambio, el test con errores agrupados rechaza solo en el 4.3% de las veces, un valor cercano al 5% teórico, confirmando que este método de inferencia es el único adecuado cuando los errores están correlacionados dentro de los sitios.

La implicación que tiene este sobrerrechazo es que, debido a la construcción del modelo, debería cumplirse la hipótesis nula. Entonces, al utilizar las dos primeras estructuras de errores estamos cometiendo más del 50% de las simulaciones el error tipo I (rechazar H_0 cuando es verdadera). Como habíamos visto en el apartado a, los modelos sin clusterización subestimaban los errores estándar causando que sea más fácil rechazar la hipótesis nula.

- d) Ahora, en el apartado D) del do-file estaremos asumiendo que los efectos de sitio son fijos, que equivale a pensar en volver a correr el experimento en los mismos 100 sitios de tu estudio. Naturalmente, ahora no es sensato hacer el test de que los efectos promedio son iguales a 1, sino comparar con el promedio de la muestra $\frac{1}{100} \sum_{c=1}^{100} \eta_c$.

¿Cuál es la fracción de veces que se rechaza el test de que el coeficiente de la regresión equivale a $\frac{1}{100} \sum_{c=1}^{100} \eta_c$?

Ahora debemos contrastar si el efecto estimado coincide con el promedio observado de los efectos en estos 100 sitios, es decir:

$$H_0 : \beta = \frac{1}{100} \sum_{c=1}^{100} \eta_c = \hat{\eta}$$

La Tabla 4 muestra los resultados al repetir el experimento 1000 veces bajo esta nueva configuración. En todos los casos, la fracción de rechazos está muy por debajo del nivel nominal de 5% (o exactamente igual a 0 en el caso cluster). Esto sugiere que los tests son conservadores bajo este nuevo diseño, es decir, tienden a no rechazar la hipótesis nula incluso cuando sería apropiado hacerlo.

Cuando tratamos los efectos de sitio como fijos, la variación entre sitios ya no se interpreta como una fuente de error aleatorio adicional. En otras palabras, la correlación intra-grupo ya está completamente absorbida por los efectos fijos, de modo que la varianza estimada no necesita ajustarse por clustering. Por eso, los errores estándar clusterizados son más grandes y los tests resultan aún más conservadores (aquí 0% de rechazos).

Table 4: Tasas de Rechazo de H_0 : $\beta = \hat{\eta}$

Tipo de Error Estándar	Tasa de Rechazo
Homoscedástico	3.5%
Robusto	3.6%
Agrupado (Cluster)	0.0%

Este resultado tiene una conclusión intuitiva cuando los sitios son los mismos (efectos fijos), el parámetro de interés $\hat{\eta}$ ya captura toda la heterogeneidad observable entre ellos. No hay incertidumbre sobre de qué población provienen los sitios, por lo que la inferencia se vuelve más estable y menos propensa a errores tipo I. En cierto modo, la estimación refleja una “población completa” y no una muestra aleatoria.

- e) Compare y contraste sus respuestas en todas las partes anteriores. ¿Es válido decir que las diferencias entre errores estándar robustos y cluster pueden surgir de heterogeneidad de los efectos de tratamiento? ¿Qué más cree que pueda decir este ejercicio sobre el nivel apropiado de clustering en experimentos aleatorizados?

Los resultados dan una imagen claro y coherente:

1. En el apartado (a), establecimos el problema central. Al simular datos con un componente de error compartido a nivel de clúster ($\sigma_\eta^2 = 1$), demostramos que los errores estándar convencionales (homocedásticos y robustos) subestiman drásticamente la verdadera variabilidad del estimador. El error estándar clusterizado fue 3.5 veces mayor, revelando la magnitud de la información redundante contenida dentro de cada clúster que los otros métodos ignoran.
2. El apartado (b) funcionó como el caso base o contrafactual. Al eliminar la correlación intra-grupo ($\sigma_\eta^2 = 0$), observamos que los tres métodos de cálculo de errores estándar convergían, produciendo resultados prácticamente idénticos. Esto confirmó que, en ausencia de dependencia, los métodos estándar son suficientes y la corrección por clúster, aunque inofensiva, es innecesaria.
3. El apartado (c) fue la demostración empírica de las consecuencias inferenciales. La simulación Monte Carlo reveló una falla clara de los tests de hipótesis que no usan errores clusterizados. Con una tasa de error de Tipo I del 52.5%, en lugar del 5% nominal, probamos que ignorar la correlación intra-grupo lleva a un sobrerrechazo de la hipótesis nula. Solo el test con errores clusterizados mostró una calibración correcta (tasa de rechazo del 4.3%).
4. Finalmente, el apartado (d) exploró una solución alternativa: modelar los efectos de sitio como parámetros fijos. Este enfoque eliminó la fuente de correlación del término de error, resolviendo el problema del sobrerrechazo. Sin embargo, también cambió la naturaleza de la pregunta de investigación, condicionando la inferencia a la muestra específica de 100 sitios en lugar de a la población de la que fueron extraídos.

Por otro lado, podemos decir que la diferencia emerge no directamente de la heterogeneidad del tratamiento en este ejercicio, pero en otros casos, por lo general sí es causado por eso. En la simulación que realizamos, la necesidad de clusterizar los errores estándar no surge de la heterogeneidad de los efectos del tratamiento, sino de la presencia de un componente de error no

observado y compartido (η_c) a nivel de clúster. Este término afecta el resultado de todos los individuos en un clúster de la misma manera, independientemente de si recibieron o no el tratamiento. Es un "common shock".

Sin embargo, la heterogeneidad en los efectos del tratamiento es otra razón perfectamente válida y común por la que pueden diferenciarse los errores estándar robustos y los clusterizados. Por lo tanto, aunque nuestro ejercicio se centró en un shock común, la conclusión es más general ya que cualquier componente de error no modelado que esté correlacionado dentro de los grupos, ya sea un shock común o efectos de tratamiento heterogéneos, hará que los errores estándar robustos sean inválidos y requerirá una corrección por clúster.

Por último, la el nivel al que se clusterizan los errores estándar debe corresponder al nivel en el que se aleatorizó el tratamiento. Si un experimento aleatoriza el tratamiento a nivel de aldea (es decir, todas las personas en la aldea A están en el grupo de tratamiento y todas en la aldea B en el de control), entonces la inferencia debe clusterizar los errores estándar a nivel de aldea. Esto debido a que la aleatorización a nivel de clúster garantiza que la asignación de tratamiento sea independiente de las características no observadas del clúster (como nuestro η_c) entre clústeres, pero no rompe la correlación dentro de los clústeres. Todos los individuos en un clúster comparten el mismo estatus de tratamiento y el mismo shock no observado. Como se demostró en el apartado (c), analizar estos datos como si las observaciones fueran independientes (es decir, no clusterizar o clusterizar a un nivel inferior como el individuo) es un error metodológico grave que invalida los p-values y los intervalos de confianza.

Experimentos Estratificados

2. En clase discutimos que sucede cuando realizamos un experimento aleatorio en distintos sitios. El tratamiento T_i solo puede tomar valor de 0 o 1 y se asigna aleatoriamente dentro de cada sitio $X_i \in \{1, \dots, K\}$. Por lo tanto queremos comparar tratamiento y control dentro de cada sitio.

Nos interesa estimar el siguiente modelo por OLS

$$y_i = S_i' \Pi + \delta T_i + u_i,$$

donde $S_i = (\mathbf{1}\{X_i = 1\}, \dots, \mathbf{1}\{X_i = K\})'$ indica los efectos fijos por cada sitio. El objetivo de esta pregunta es entender qué está estimando exactamente δ por OLS.

- a) ¿Este modelo incluye todas las posibles interacciones (es decir, es un modelo completamente saturado)? ¿Si el efecto fuese homogéneo en distintos sitios entonces qué captura δ ? Explique en palabras.

No está saturado, el modelo contiene efectos fijos por sitio (los indicadores en S_i) y un efecto promedio del tratamiento δ , pero no incluye las interacciones entre tratamiento y sitio (es decir, no incluye términos $T_i \cdot \mathbf{1}\{X_i = k\}$ para cada k). Un modelo completamente saturado respecto a sitios y tratamiento tendría un coeficiente de tratamiento distinto por cada sitio; es decir, incluiría K indicadores de tratamiento por sitio (o, equivalentemente, los K interactores $T_i \cdot \mathbf{1}\{X_i = k\}$). Por tanto, la especificación dada no es saturada.

Por otro lado, ssi el efecto del tratamiento es homogéneo entre sitios (es decir, existe un δ^* tal que para todo i y todo sitio k , el efecto causal del tratamiento es δ^*), entonces el coeficiente δ

estimado por OLS en la especificación con efectos fijos por sitio estima consistentemente ese efecto homogéneo δ^* . En palabras: al controlar por efectos fijos de sitio, la regresión compara observaciones tratadas y de control dentro de cada sitio, por lo que δ representa el efecto promedio del tratamiento dentro de sitios, que bajo homogeneidad coincide con el efecto promedio poblacional.

- b) Por el teorema de Frisch-Waugh-Lovell podemos residualizar T_i y Y_i del efecto de X_i , y escribir el coeficiente como:

$$\delta = E \left[\hat{T}_i^2 \right]^{-1} E \left[\hat{T}_i \hat{Y}_i \right] = \frac{E \left[(Y_i - E[Y_i|X_i])(T_i - E[T_i|X_i]) \right]}{E \left[(T_i - E[T_i|X_i])^2 \right]}$$

dado que la regresión de T_i sobre X_i es saturada, y lo mismo ocurre con Y_i (la regresión obtiene el CEF verdadero).

Se pide mostrar lo siguiente

$$E \left[(T_i - E[T_i|X_i])^2 \right] = E \left[P(T_i|X_i)(1 - P(T_i|X_i)) \right],$$

donde T_i toma valor 0 o 1 (¿qué implica esto sobre T_i^2 ?) y por tanto $E(T_i|X_i) = P(T_i|X_i)$.
(Pista: recuerde la propiedad de esperanzas iteradas $E[Y_i] = E[E[Y_i|X_i]]$)

Demostración:

Sabiendo que $T_i \in \{0, 1\}$ implica $T_i^2 = T_i$. Además:

$$E[T_i | X_i] = P(T_i = 1 | X_i) \equiv p(X_i).$$

Usando la descomposición por varianza condicional:

$$E[(T_i - E[T_i | X_i])^2] = E[E[(T_i - E[T_i | X_i])^2 | X_i]].$$

Pero para cada valor de X_i la cantidad interior es simplemente la varianza condicional:

$$E[(T_i - E[T_i | X_i])^2 | X_i] = \text{Var}(T_i | X_i).$$

Usando $T_i^2 = T_i$ obtenemos:

$$\text{Var}(T_i | X_i) = E[T_i^2 | X_i] - (E[T_i | X_i])^2 = E[T_i | X_i] - (E[T_i | X_i])^2 = p(X_i)(1 - p(X_i)).$$

Por tanto, tomando esperanza incondicional:

$$E[(T_i - E[T_i | X_i])^2] = E[p(X_i)(1 - p(X_i))] = E[P(T_i | X_i)(1 - P(T_i | X_i))],$$

- c) Ahora muestre que:

$$E[T_i(T_i - E[T_i | X_i]) | X_i] = P(T_i | X_i)(1 - P(T_i | X_i))$$

Demostración:

Sea $p(X_i) = P(T_i = 1 | X_i) = E[T_i | X_i]$.

Además, como $T_i \in (0, 1)$ tenemos $T_i^2 = T_i$ y $E[T_i^2 | X_i] = E[T_i | X_i] = p(X_i)$. Entonnces:

$$E[T_i(T_i - E[T_i | X_i]) | X_i] = E[T_i^2 | X_i] - E[T_i | X_i] E[T_i | X_i] = p(X_i) - (p(X_i))^2 = p(X_i)(1 - p(X_i)).$$

d) Recuerde que siempre podemos escribir el siguiente modelo

$$Y_i = Y_i(1)T_i + Y_i(0)(1 - T_i) = Y_i(0) + (Y_i(1) - Y_i(0))T_i$$

Muestre que:

$$E[Y_i | X_i, T_i] = E[Y_i | X_i, T_i = 0] + \Delta(X_i) T_i = E[Y_i(0) | X_i] + \Delta(X_i) T_i,$$

donde $\Delta(X_i) \equiv E[Y_i(1) - Y_i(0) | X_i]$.

Demostración:

Partiendo de la identidad de resultados potenciales:

$$Y_i = Y_i(0) + (Y_i(1) - Y_i(0))T_i.$$

Tomando esperanza condicional dado X_i y T_i :

$$\begin{aligned} E[Y_i | X_i, T_i] &= E[Y_i(0) + (Y_i(1) - Y_i(0))T_i | X_i, T_i] \\ &= E[Y_i(0) | X_i, T_i] + E[(Y_i(1) - Y_i(0))T_i | X_i, T_i]. \end{aligned}$$

Como T_i es conocida dentro de la condición (X_i, T_i) , puede sacarse fuera de la esperanza en el segundo término:

$$E[Y_i | X_i, T_i] = E[Y_i(0) | X_i, T_i] + T_i E[Y_i(1) - Y_i(0) | X_i, T_i].$$

Si además asumimos asignación aleatoria del tratamiento dentro de cada sitio entonces las esperanzas condicionales anteriores no dependen de T_i , y se simplifican a cantidades solo condicionadas en X_i :

$$E[Y_i(0) | X_i, T_i] = E[Y_i(0) | X_i], \quad E[Y_i(1) - Y_i(0) | X_i, T_i] = E[Y_i(1) - Y_i(0) | X_i].$$

Definiendo $\Delta(X_i) \equiv E[Y_i(1) - Y_i(0) | X_i]$, de (i) se obtiene

$$E[Y_i | X_i, T_i] = E[Y_i(0) | X_i] + \Delta(X_i) T_i.$$

e) Mostrar, en base a la ecuación mostrada en la parte b) que

$$\delta = \frac{E[Y_i(T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]} - \frac{E[E[Y_i | X_i](T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]},$$

y además mostrar que el segundo término de esta ecuación es exactamente cero.

Demostración:

Partimos de la expresión obtenida en (b)

$$\delta = \frac{E[(T_i - E[T_i | X_i])(Y_i - E[Y_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]}.$$

Descomponiendo el numerador,

$$\begin{aligned} E[(T_i - E[T_i | X_i])(Y_i - E[Y_i | X_i])] &= E[(T_i - E[T_i | X_i])Y_i] \\ &\quad - E[(T_i - E[T_i | X_i])E[Y_i | X_i]] \\ &= E[Y_i(T_i - E[T_i | X_i])] \\ &\quad - E[E[Y_i | X_i](T_i - E[T_i | X_i])]. \end{aligned}$$

Dividiendo por $E[(T_i - E[T_i | X_i])^2]$ obtenemos la identidad pedida:

$$\delta = \frac{E[Y_i(T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]} - \frac{E[E[Y_i | X_i](T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]}.$$

Para que el segundo término es cero. Usando la ley de las expectativas iteradas y la propiedad de sacarlo fuera en la esperanza condicional,

$$\begin{aligned} E[E[Y_i | X_i](T_i - E[T_i | X_i])] &= E[E[E[Y_i | X_i](T_i - E[T_i | X_i]) | X_i]] \\ &= E[E[Y_i | X_i]E[(T_i - E[T_i | X_i]) | X_i]]. \end{aligned}$$

Pero por definición $E[(T_i - E[T_i | X_i]) | X_i] = E[T_i | X_i] - E[T_i | X_i] = 0$.

Entonces la esperanza interior es cero y por tanto

$$E[E[Y_i | X_i](T_i - E[T_i | X_i])] = 0.$$

f) Ahora escribiremos

$$\begin{aligned} \delta &= \frac{E[E[Y_i | X_i, T_i](T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]} \\ &= \frac{E[(E[Y_i | X_i, T_i = 0] + \Delta(X_i)T_i)(T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]} \\ &= \frac{E[E[Y_i | X_i, T_i = 0](T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]} \\ &\quad + \frac{E[\Delta(X_i)T_i(T_i - E[T_i | X_i])]}{E[(T_i - E[T_i | X_i])^2]} \end{aligned}$$

y se pide mostrar que el primer término es exactamente cero.

Demostración:

Definiendo la función $h(X_i) \equiv E[Y_i|X_i, T_i = 0]$. Observa que $h(X_i)$ es X_i -medible (es una función de X_i). Entonces:

$$\begin{aligned} E[E[Y_i|X_i, T_i = 0](T_i - E[T_i|X_i])] &= E[h(X_i)(T_i - E[T_i|X_i])] \\ &= E[E[h(X_i)(T_i - E[T_i|X_i])|X_i]] \\ &= E[h(X_i)E[(T_i - E[T_i|X_i])|X_i]]. \end{aligned}$$

Pero por definición $E[(T_i - E[T_i|X_i])|X_i] = E[T_i|X_i] - E[T_i|X_i] = 0$. Luego la esperanza interior es cero y por tanto:

$$E[E[Y_i|X_i, T_i = 0](T_i - E[T_i|X_i])] = 0.$$

g) Finalmente, utilicen los resultados del apartado b) y c) para mostrar que llegamos a la expresión

$$\delta = E[\delta(X_i)w(X_i)],$$

donde $w(X_i) = \sigma_T^2(X_i)/E[\sigma_T^2(X_i)]$ y $\sigma_T^2(X_i) = P(T_i | X_i)(1 - P(T_i | X_i))$.

Demostración:

Partimos de la expresión (parte b y d)

$$\delta = \frac{E[(T_i - E[T_i|X_i])(Y_i - E[Y_i|X_i])]}{E[(T_i - E[T_i|X_i])^2]} = \frac{E[E[Y_i|X_i, T_i](T_i - E[T_i|X_i])]}{E[(T_i - E[T_i|X_i])^2]}.$$

Usando la identidad del apartado (d) $E[Y_i|X_i, T_i] = E[Y_i(0)|X_i] + \Delta(X_i)T_i$ y la descomposición dada en (f), obtenemos

$$\delta = \frac{E[E[Y_i|X_i, T_i = 0](T_i - E[T_i|X_i])]}{E[(T_i - E[T_i|X_i])^2]} + \frac{E[\Delta(X_i)T_i(T_i - E[T_i|X_i])]}{E[(T_i - E[T_i|X_i])^2]}.$$

Por el apartado (f) el primer término es exactamente 0. Por tanto

$$\delta = \frac{E[\Delta(X_i)T_i(T_i - E[T_i|X_i])]}{E[(T_i - E[T_i|X_i])^2]}.$$

Condicionando en X_i y usando linealidad de la esperanza,

$$\delta = \frac{E[\Delta(X_i)E[T_i(T_i - E[T_i|X_i])|X_i]]}{E[(T_i - E[T_i|X_i])^2]}.$$

Pero por el apartado (c) sabemos que

$$E[T_i(T_i - E[T_i|X_i])|X_i] = P(T_i | X_i)(1 - P(T_i | X_i)) = \sigma_T^2(X_i).$$

Sustituyendo,

$$\delta = \frac{E[\Delta(X_i)\sigma_T^2(X_i)]}{E[\sigma_T^2(X_i)]}.$$

Definiendo $\delta(X_i) \equiv \Delta(X_i)$ y los pesos

$$w(X_i) \equiv \frac{\sigma_T^2(X_i)}{E[\sigma_T^2(X_i)]},$$

llegamos finalmente a:

$$\delta = E[\delta(X_i)w(X_i)]$$

h) ¿Si todos los $\delta(X_i)$ son positivos, hay manera de que el δ estimado salga negativo? ¿Le parece esto una propiedad buena o mala?

No, en población no puede. Como mostramos,

$$\delta = E[\delta(X_i)w(X_i)],$$

donde $w(X_i) \geq 0$ para todo X_i y la esperanza de los pesos implícitamente es 1. Si $\delta(X_i) \geq 0$ para todo X_i , entonces la combinación cumple $E[\delta(X_i)w(X_i)] \geq 0$; y si existe alguna X tal que $\delta(X) > 0$ con $\sigma_T^2(X) > 0$, entonces $\delta > 0$. Por último, creo que es una propiedad buena en el sentido de coherencia (el estimador preserva el signo cuando los efectos condicionales lo comparten).

Programa Social Juntos

3. En esta pregunta evaluaremos la importancia del supuesto de independencia condicional para el análisis de políticas sociales, usando como ejemplo el programa social *Juntos*. Este programa promueve que las mujeres gestantes, niñas, niños y adolescentes de los hogares más pobres, con su participación y compromiso voluntario, accedan a la salud preventiva materno-infantil y a los servicios de escolaridad sin deserción.

En la carpeta llamada **Juntos** pueden encontrar un do-file que corre una rutina de nearest neighbor matching en base a unas variables de control definidas en el código. La base utilizada es una muestra aleatoria de la *Encuesta Demográfica y de Salud* (ENDES), dirigida a mujeres y sus hijos.

- a) Corran todo ese código y hagan una regresión entre variables dependientes de parto y post-parto y la variable de tratamiento, controlando por los controles indicados en la variable global `$controls`. ¿Utilizar errores estándar robustos o cluster a nivel región (variable llamada `v024`) hace una diferencia? ¿Cómo lo interpretarían bajo los ojos de la pregunta 1 de este trabajo calificado?

En la Tabla 5, se observa que el programa tiene efectos estadísticamente significativos y en la dirección esperada sobre la atención médica del parto, la reducción de partos en casa y el acceso a suplementos de vitamina A. En cambio, el efecto sobre la desnutrición no es significativo.

Al comparar los errores estándar robustos y los clusterizados a nivel de región (`v024`), los coeficientes permanecen iguales, pero los errores estándar aumentan al aplicar el agrupamiento. Por ejemplo, para la variable “Asistencia de doctor en el parto”, el error estándar pasa de 0.028 (robusto) a 0.033 (cluster), reduciendo el nivel de significancia de 1% a 5%. Este patrón se repite para otras variables, evidenciando la presencia de correlación intra-regional: los individuos dentro de una misma región comparten factores no observados que afectan sus resultados, como infraestructura sanitaria u otras variables de calidad de vida.

En este sentido, los errores estándar clusterizados son más apropiados para la inferencia, pues corrigen la subestimación de la varianza provocada por la dependencia entre observaciones. Bajo la lógica discutida en la Pregunta 1, esto implica que el supuesto de independencia condicional se cumple condicionalmente a nivel de región y no necesariamente a nivel individual. Por tanto, aunque los coeficientes y direcciones de los efectos son consistentes, la magnitud de la varianza estimada varía sustancialmente, y las conclusiones sobre significancia deben tomarse de forma más conservadora.

- b) Este método de matching es un método no-paramétrico para controlar por estas características. ¿Cómo cambian los resultados si no hubiéramos corrido nada desde la línea 112 del do-file y simplemente hubiéramos hecho una regresión lineal de la forma `reg dep treated $controls`?

En este caso, omitiendo el proceso de matching y estimando directamente que los resultados mantienen el mismo signo, pero los coeficientes son más pequeños en magnitud y los errores estándar son menores en la estimación sin matching. Por ejemplo, el efecto de Juntos sobre la asistencia médica en el parto disminuye de 0.092 a 0.073, y el de parto en casa de -0.141 a -0.084 . De igual manera, el coeficiente de vitamina A se reduce de 0.078 a 0.049, mientras que el efecto sobre desnutrición incluso cambia de signo.

Estas diferencias reflejan que el matching logra corregir parte del sesgo de selección, ya que al restringir la comparación a mujeres y niños con características similares, se obtiene una estimación más creíble del efecto promedio sobre los tratados (ATT). Sin embargo, el costo de este mayor control es una reducción del tamaño muestral efectivo (de más de 4000 a cerca de 1000 observaciones), lo que incrementa la varianza de los estimadores y reduce la precisión estadística.

En contraste, las regresiones sin matching se benefician de un mayor número de observaciones, pero asumen un modelo paramétrico lineal y el cumplimiento estricto del supuesto de independencia condicional (trade-off), lo que puede generar estimadores sesgados si las diferencias entre beneficiarios y no beneficiarios no son completamente capturadas por los controles.

En conclusión, el análisis evidencia que el uso del matching permite aproximarse mejor a un escenario de comparación causal, sacrificando eficiencia a cambio de validez externa. Por su parte, las regresiones lineales tradicionales producen resultados más precisos, pero potencialmente menos confiables en términos de interpretación causal. De esta forma, ambos métodos son complementarios. el primero enfatiza la validez del contrafactual, y el segundo la precisión estadística de las estimaciones.

Table 5: Comparación de Resultados: Con vs Sin Matching - Programa Juntos

Variable Dependiente	Con Matching		Sin Matching	
	Robusto	Cluster	Robusto	Cluster
Asistencia Doctor Parto				
Coefficiente	0.092***	0.092**	0.073***	0.073**
Error Estándar	(0.028)	(0.033)	(0.022)	(0.028)
N	1012	1012	4301	4301
Parto en Casa				
Coefficiente	-0.141***	-0.141**	-0.084***	-0.084*
Error Estándar	(0.028)	(0.061)	(0.022)	(0.044)
N	1012	1012	4301	4301
Vitamina A				
Coefficiente	0.078***	0.078*	0.049**	0.049*
Error Estándar	(0.026)	(0.038)	(0.023)	(0.026)
N	1012	1012	3584	3584
Desnutrición				
Coefficiente	-0.029	-0.029	0.038	0.038
Error Estándar	(0.030)	(0.046)	(0.024)	(0.028)
N	1012	1012	4301	4301

Notas: *** $p < 0.01$, ** $p < 0.05$, * $p < 0.10$. Errores estándar entre paréntesis.